



23/10/2024

APLICAÇÃO DE REDES NEURAIS RECORRENTES PARA CORRESPONDÊNCIA DE DADOS DE SÍSMICA TIME-LAPSE



Autora:

Poliana Ellen de Araújo

Co-Autores:

Tiago Tavares Leite Barros

Ramon Cristian Fernandes Araújo

Orientador:

Gilberto Corso



23/10/2024

APLICAÇÃO DE REDES NEURAIS RECORRENTES PARA CORRESPONDÊNCIA DE DADOS DE SÍSMICA TIME-LAPSE



OBJETIVOS DE DESENVOLVIMENTO SUSTENTÁVEL DA ONU



MOTIVAÇÃO






MOTIVAÇÃO

Análise de dados sísmicos







MOTIVAÇÃO


Como observar o comportamento de reservatórios de petróleo no subsolo em alto mar?




MOTIVAÇÃO










Reservatório



MOTIVAÇÃO




Baseline



Monitor



MOTIVAÇÃO



Reservatório



OBJETIVOS E METAS

OBJETIVO

Desenvolver uma Rede Neural Recorrente baseada em GRU que aprende a correspondência entre dados sísmicos simulados.

RESULTADOS ESPERADOS

- Mudanças relevantes associadas ao reservatório de petróleo e suprimir o ruídos.
- Ter uma boa acurácia na detecção de variações nas propriedades do reservatório ao longo do tempo.
- Análise mais precisa e eficiente na exploração e monitoramento de reservatórios de petróleo.



Metodologia

REDES NEURAIS RECORENTES

Redes Neurais Recorrentes são boas com sequência de dados temporais.

Problema: desaparecimento do gradiente.

Solução: célula GRU (do português, Unidade Recorrente Fechada)

Dados de entrada: dados monitor.

Dados de saída: dados sem ruídos.




Figura 1



RESULTADOS




Figura 2





RESULTADOS

3 TRAÇOS




Figura 3

	Inteiro	Chegada	Profundo	Reserva
Monitor:	13,64	13,65	9,21	8,61
Inferido:	0,34	0,31	3,07	2,6



RESULTADOS

3 TRAÇOS




Figura 4

	Inteiro	Chegada	Profundo	Reserva
Monitor:	14,02	14,03	9,27	8,66
Inferido:	0,34	0,31	3,01	2,55



RESULTADOS

3 TRAÇOS




Figura 5

	Inteiro	Chegada	Profundo	Reserva
Monitor:	14,41	14,42	9,33	8,74
Inferido:	0,64	0,63	2,95	2,5

RESULTADOS

3 TRAÇOS




Figura 6



CONCLUSÕES

Resultados se aproximam do esperado.

Deslocamento de informação ao longo do tempo.

Trabalhos futuros:

- Expandir treinamento para outras regiões do “sismograma”;
- Conseguir evitar overfitting.




Figura 7

AGRADECIMENTOS



REFERÊNCIAS



GERON, Aurélien. Mãos à obra: machine learning com Scikit-Learn, Keras & TensorFlow. 2. ed. São Paulo: Alta Books, 2020.

Alali, A., Kazei, V., Sun, B., Smith, R., Nivlet, P., Bakulin, A., & Alkalifah, T. (2020). Cross-equalization of time-lapse seismic data using recurrent neural networks. SEG Technical Program Expanded Abstracts 2020. doi:10.1190/segam2020-3424773.1